# KSPHM-KIMM 기계 데이터 챌린지 2026

Technical Report — 베어링 잔여수명(RUL) 예측 파이프라인

| 팀명 포크착기 | 제출 파일 rul_pipeline_final_submit_nocache.py | 언어 Python 3.10+ |
|---|---|---|

## 1. 개요 (Overview)

본 파이프라인은 KSPHM-KIMM 2026 베어링 잔여수명(RUL) 예측 챌린지를 위해 설계된 End-to-End 예측 시스템입니다. 원시 TDMS 진동 데이터(25.6 kHz, 4-채널)에서 물리·통계적 특징을 추출하고, 복수의 이질적 앵커(ML 앙상블, 지수 외삽, DTW 유사도, 위상 매칭, 라이브러리 사전)를 상태 기반으로 통합하여 최종 RUL을 산출합니다. 데이터 로드부터 제출 파일 생성까지 단일 스크립트(Python)로 실행됩니다.

| 피처 수 | ~70+ | 앙상블 모델 | 220개 | CV 방식 | LOBO + K50 | 앵커 종류 | 5가지 | RUL 클립 | 300s ~ 90,000 s | 재현성 | seed=42 고정 |
|---|---|---|---|---|---|---|---|---|---|---|---|

## 2. 전체 파이프라인 구조 (Pipeline Architecture)

| | | |
|---|---|---|
| Step 0 | 데이터 준비 | TDMS → merged_features.csv 자동 빌드 (없는 경우) |
| Step 1 | Train 로드 | merged_features.csv → DataFrame, 시퀀스 피처 파생 |
| Step 2 | Test 추출 | Test/*.zip TDMS → 피처 추출, 시퀀스 피처 부가 |
| Step 3 | 피처 선택 | Train/Test 공통 피처 + 고상관(r>0.999) 중복 제거 |
| Step 4 | LOBO/K50 CV | Leave-One-Bearing-Out + K50 stage scale 보정 |
| Step 5 | 앙상블 학습 | 전체 Train으로 최종 앙상블(220 모델) 학습 |
| Step 6 | Test 예측 | 5-앵커 블렌딩 + 상태 기반 최종 결정 레이어 |
| Step 7 | 저장 · 제출 | 포크착기_validation.xlsx + 진단 파일 출력 |

## 3. 피처 추출 (Feature Engineering)

각 TDMS 파일(1분, 25.6 kHz, CH1~CH4)에서 아래 범주의 특징을 추출합니다. RPM은 CH1 FFT 5~25 Hz 대역 피크에서 추정 후 700/950 rpm으로 스냅합니다.

| 범주 | 주요 피처 | 설명 |
|---|---|---|
| 시간 영역 | RMS, IQR, Q75, Log-RMS, Shape Factor, Mean-Abs | 진폭 크기 및 분포 특성 |
| 주파수 영역 | Welch PSD 대역비 (0-100, 1k-3k, 3k-6k, 6k-9k, 10k-12.8k Hz) | 주파수 대역별 에너지 점유율 |
| 결함 주파수 | BPFI/BPFO 1~3차 고조파 에너지 비율, 피크 진폭 | 베어링 결함 특성 주파수 에너지 |
| 포락선 분석 | Hilbert Envelope RMS, BPFI/BPFO 대역 비율, 첨도 | 진폭 변조 패턴 감지 |
| 웨이블릿(DWT) | cD2, cD3 에너지 비율 (pywt 가용 시) | 과도적 충격 성분 분해 |
| 사이드밴드 | BPFI/BPFO 사이드밴드 비율 | 변조 심도 (결함 진전 지표) |
| 채널 간 상관 | corr(CH1-CH3), (CH1-CH4), (CH2-CH3), (CH2-CH4), (CH3-CH4) | 전/후방 베어링 동기화 |

| | | |
|---|---|---|
| 시퀀스 파생 | 롤링 집계(3/6 윈도우), 초기 6파일 대비 상대값, 누적 열화(cumdmg), cmax | 장기 열화 트렌드 추적 |

## 4. 복합 건전성 지표 (Composite Health Index, CHI)

7개 피처를 가중합산한 단일 스칼라 시계열 CHI를 상태 진단·앵커 생성의 공통 기반으로 활용합니다. 단조 증가 강제(Isotonic)를 적용하지 않고, Savitzky-Golay 스무딩(w=5, poly=2)과 롤링 중앙값(w=3)만 적용하여 말기 가속·진동 정보를 보존합니다.

| 피처 | 가중치 | 역할 |
|---|---|---|
| CH4_rms_rel_init6 | 0.30 | 후방 수직 진동 상대 RMS (주 지표) |
| CH3_rms_rel_init6 | 0.20 | 후방 축방향 진동 상대 RMS |
| env_rms_all_mean_rollmean_6 | 0.20 | 포락선 RMS 이동평균 (열화 감지) |
| CH4_bpfi_h3_energy_ratio | 0.10 | BPFI 3차 고조파 (내륜 결함) |
| CH4_bpfo_h2_energy_ratio | 0.08 | BPFO 2차 고조파 (외륜 결함) |
| Vibration_CH4_env_band_bpfi_2x_ratio | 0.07 | 포락선 BPFI 2배 대역비 |
| CH4_band_0_100_energy_ratio | 0.05 | 극저주파 에너지 (케이지 마모) |

CHI 분위수(chi_q)는 전체 Train CHI 분포 기준으로 산출되며, 단계 분류(stage: 0.30/0.40/0.50/0.65/0.80) 및 상태 분류(stable/mid/late 등)에 활용됩니다.

## 5. 5가지 예측 앵커 (Five Prediction Anchors)

| 앵커 | 방법 | 가중치 | 세부 설명 |
|---|---|---|---|
| ML 앙상블 | Ridge/BayesianRidge/RF ET/GBM/LightGBM/XGBoost (최대 220 모델) | 0.90 | log1p(RUL) 회귀. 고상관 피처 제거 후 StandardScaler 적용. 전역 평균으로 회귀하는 경향을 낮은 가중치로 보완. |
| EP 지수 외삽 | CHI 말기 세그먼트 선형 로그 피팅 → 임계값 도달 시간 | 0.38~0.75 | onset 이후 또는 변화율 > 0.006 시 가중치 상향. 안정 구간에서는 낮춤. |
| DTW 유사도 | Test CHI를 Train 궤적에 EOL-relative 위치 정렬 후 DTW | 0.62 | 상위 3개 유사 Train 궤적의 역거리 가중 RUL 추정. |
| Phase 매칭 | CHI 수준 + 변화율로 Train 모든 시점 중 최근접 탐색 | 0.65~0.90 | CHI < 0.80이면 가중치 상향. 상위 5개 위상 유사 시점 가중 집계. |
| Library 사전(Lib) | 관측 파일 수/chi_q/curr_rel/변화율로 Train 테이블 매칭 | 1.20 | 상태별 분위수(stable: 0.72, mid: 0.56, late: 0.55) 적용. 과소예측 방어에 핵심 역할. |

## 6. 상태 기반 결정 레이어 (State-Aware Decision Layer)

CHI 분위(chi_q), 현재 수준(curr_rel), 변화율(rate_ratio) 조합으로 6가지 상태를 분류하고, 상태별 서로 다른 사후 추정 공식을 적용합니다.

| 상태 | 진입 조건 | 사후 추정 공식 | 핵심 보호 목적 |
|---|---|---|---|
| stable | chi_q<0.35, rr<0.004, curr_rel<1.25 | 0.72×scaled + 0.28×hi 최대 13h 클립 | 초기 과소예측 방어 |
| mid | 그 외 일반 구간 | 0.65×scaled + 0.35×q65 (중기 장기 지원 조건부 12~13.3h) | 중기 과소예측 방어 |
| late | chi_q≥0.86·curr_rel≥1.35 또는 chi_q≥0.90 | 0.45×scaled + 0.55×q_late 최대 7h 클립 (지지 앵커 있으면 완화) | 말기 과대예측 패널티 방어 |
| transient recovery | chi_q≥0.70, curr_rel≥1.45, rr<0 | 0.45×scaled + 0.55×hi 6.5~7.5h 구간 클립 | 일시적 HI 상승 후 안정화 대응 |

| | | | |
|---|---|---|---|
| collapse | low앵커≤4h, med≥6h, chi_q<0.78 | 0.45×scaled + 0.55×med rescue 앵커(lib/phase) 보완 | 앵커 이상치 방어 |
| signal reversal | EP 실패, chi_q<0.18, curr_rel>0.95, rr<-0.04 | 0.45×lo + 0.55×scaled 최대 2h 클립 | HI 꺾임 오감지 방어 |

## 7. 교차검증 및 Stage Scale 보정 (LOBO + K50 CV)

Leave-One-Bearing-Out(LOBO) CV를 수행하여 관측 비율(30/40/50/65/80%)별 예측 정확도를 측정하고, 추가로 관측 50파일 고정(K50, 가중치=5.0) CV를 수행합니다. stage별로 CV 오차를 최소화하는 scale 계수(0.70~1.60 탐색)를 grid search로 산출합니다. 단조 감소를 강제하고 최솟값 하한(min_stage_scale)을 두어 과보정을 방지합니다.

| Stage (%) | Fallback Scale | Min Scale | 비고 |
|---|---|---|---|
| 30 | 1.25 | 1.25 | 초기 관측: 과소예측 방어 |
| 40 | 1.20 | 1.15 | |
| 50 | 1.25 | 1.20 | |
| 65 | 0.85 | 0.80 | 중후기: 실제에 근접 |
| 80 | 0.85 | 0.80 | 말기: 과대예측 방어 |

### 앙상블 구성 (전체 Train 학습 시)

- Ridge(alpha=0.4/1.0/2.0/5.0) + BayesianRidge: 선형 기저 (StandardScaler 적용)
- RandomForestRegressor(n=250) + ExtraTreesRegressor(n=250): 비선형 앙상블
- GradientBoostingRegressor(n=170, lr=0.035, depth=2): 느린 학습률 부스팅
- LightGBM(n=260, lr=0.025, leaves=15) / XGBoost(n=260, lr=0.025, depth=3): 가용 시
- 총 220 모델 (라운드당 3~5 모델 × 12 라운드 + 선형 5)

## 8. 앵커 블렌딩 공식 (Anchor Blending)

단순 가중 평균은 이상치 앵커에 취약하므로, 상태별 가중 분위수(weighted quantile)를 사용합니다.

| 단계 | 수식 | 목적 |
|---|---|---|
| blend_anchors() | raw = 0.62×WQ(q_state) + 0.26×WQ(0.5) + 0.12×avg (q_state: stable=0.72, mid=0.62, late=0.55) | 이상치 앵커 영향 억제 |
| Stage Scale 적용 | scaled = clip(raw × stage_scale, 300s, 90000s) | CV 보정으로 단계별 편향 교정 |
| final_decision() | posterior = f(state, scaled, anchor 분위수) | 상태별 안전 구간 내 최종 RUL |

## 9. 노이즈 및 데이터 특이사항 대응

- 고노이즈 환경 대응: 각 채널 신호를 mu ± 5sigma로 클리핑 후 피처 추출.
- RPM 추정 강건화: CH1 FFT 주파수 피크 기반 RPM 추정 후 700/950 rpm으로 스냅(snap_rpm).
- onset 감지 강화: 단발 스파이크 무시를 위한 CUSUM 방식 적용(threshold=3.5σ, Train4 누락 파일 고려).
- Train4 마지막 파일 누락: FAQ 공지 반영. TDMS 파일 수 기준 RUL 산출로 수명 산정 일관성 유지.
- Test RPM 미제공: 진동 데이터에서 RPM 자동 추정(FAQ 확인). BPFI/BPFO 주파수 스케일링에 반영.
- 데이터 누락 구간(측정 외): 미측정 구간 고장 불확실성을 Library Prior 및 상태별 상한 클립으로 흡수.
- 리키지 피처 방지: rul, time_sec 등 LEAKY_TOKENS 포함 피처를 학습에서 자동 제외.

## 10. 실행 환경 및 라이브러리 (Environment)

| 항목 | 값 |
|---|---|
| 운영체제 | Ubuntu 22.04 / Windows 10 (Python 3.10+) |

| | |
|---|---|
| 필수 라이브러리 | numpy, pandas, scipy, scikit-learn, nptdms, openpyxl, reportlab |
| 선택 라이브러리 | lightgbm (≥3.3), xgboost (≥1.7), pywt (PyWavelets), dtaidistance |
| 입·출력 경로 | 입력: /data/Train/, /data/Test/ \| 출력: /data/rul_output/ |
| 데이터 형식 | float32 (진동 배열), float64 (피처 계산), UTF-8-sig (CSV) |
| 난수 고정 | seed=42 (numpy, random, sklearn estimators 통일) |
| 실행 명령 | python rul_pipeline_final_submit_nocache.py |

merged_features.csv가 없으면 Train/*.zip에서 자동 빌드하며, KSPHM_BASE 환경변수로 데이터 경로를, KSPHM_OUT_DIR로 출력 경로를 오버라이드할 수 있습니다.

## 11. 출력 파일 (Output Files)

| 파일명 | 내용 |
|---|---|
| 포크착기_validation.xlsx | 공식 제출 파일 (File, RUL_Score 컬럼) |
| rul_submission.xlsx | Test_ID, RUL_sec 컬럼 제출용 |
| rul_diagnostics.xlsx | 예측 진단 정보: Diagnostics / LOBO_K50_CV / Features / Stage_Scales / Config 시트 |

## 12. 설계 원칙 요약 (Design Principles)

- 과소예측 패널티 중점 방어: 대회 채점 함수가 과대예측보다 과소예측에 강한 패널티를 부여하므로, Library Prior(가중치 1.20) 및 stable/mid 상태 상한 클립으로 안전 마진 확보.
- 앵커 이상치 완화: 가중 중앙값/분위수 기반 블렌딩으로 단일 앵커의 극단값 영향 억제.
- 단조 증가 강제 미적용: 말기 열화 가속·진동 정보 손실 방지 (Isotonic 제거, SG 스무딩만 적용).
- 노이즈 강건성: CUSUM onset, 3.5σ 클리핑, 롤링 집계로 고노이즈 환경 안정성 확보.
- 단일 파일 실행: 사전 빌드된 피처 CSV 없이 TDMS에서 전체 파이프라인 자동 실행 가능.